

Lagrange函数及其对偶函数

对于标准形式的优化问题：

$$\begin{aligned} & \text{minimize } f_0(x) \\ & \text{subject to } f_i(x) \leq 0, i = 1, 2, \dots, m \\ & \qquad \qquad h_i(x) = 0, i = 1, 2, \dots, p \end{aligned}$$

拉格朗日函数为：

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)$$

向量 λ 和 v 是对偶变量或者是这个式子的Lagrange乘子

Lagrange对偶函数是Lagrange函数关于 x 取得的最小值：

$$\begin{aligned} g(\lambda, v) &= \inf_{x \in D} L(x, \lambda, v) \\ &= \inf_{x \in D} (f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)) \end{aligned}$$

对偶函数是一族关于 (λ, v) 的放射函数的逐点下确界，所以即使原问题不是凸的，对偶函数也是凹的

对偶函数构成了原问题最优值 p^* 的下界：即对任意 $\lambda \geq 0$ 和 v ，下式成立：

$$g(\lambda, v) \leq p^*$$

证明：

设 \hat{x} 是原问题的一个可行点，即 $f_i(\hat{x}) \leq 0, h_i(x) = 0$ ，则有：

$$\sum_i^m \lambda_i f_i(\hat{x}) + \sum_{i=1}^p v_i h_i(\hat{x}) \leq 0$$

代入Lagrange函数有：

$$\begin{aligned} L(\hat{x}, \lambda, v) &= f_0(\hat{x}) + \sum_{i=1}^m \lambda_i f_i(\hat{x}) + \sum_{i=1}^p v_i h_i(\hat{x}) \\ &\leq f_0(\hat{x}) \end{aligned}$$

因此：

$$g(\lambda, v) \leq L(\hat{x}, \lambda, v) \leq f_0(\hat{x})$$

考虑标准形式的线性规划问题：

$$\begin{aligned} & \text{minimize } c^T x \\ & \text{subject to } Ax = b \\ & \qquad \qquad x \geq 0 \end{aligned}$$

其拉格朗日函数为：

$$\begin{aligned} L(x, \lambda, v) &= c^T x - \sum_{i=1}^n \lambda_i x_i + v^T (Ax - b) \\ &= -bv^T + (c + A^T v - \lambda)^T x \end{aligned}$$

对偶函数为：

$$\begin{aligned} g(\lambda, v) &= \inf_x L(x, \lambda, v) \\ &= -b^T v + \inf_x (c + A^T v - \lambda)^T x \end{aligned}$$

线性函数只有恒为0时才有下界，因此：

$$g(\lambda, v) = \begin{cases} -b^T v & c + A^T v - \lambda = 0 \\ -\infty & \text{其它情况} \end{cases}$$

Lagrange对偶问题

Lagrange对偶函数给出了优化问题最优值 p^* 的一个下界，一个自然的问题是：从Lagrange函数能够得到的最好下界是什么？可以将这个问题表述为优化问题：

$$\begin{aligned} & \text{maximize } g(\lambda, v) \\ & \text{subject to } \lambda \geq 0 \end{aligned}$$

Lagrange对偶问题是一个凸优化问题，这是因为极大化的目标函数是凹函数，且约束集合是凸集

很多情况下，我们可以识别出函数g的定义域的仿射包，并将其表示为一系列线性等式约束，这样处理之后可以得到一个等价的问题

对于标准形式的线性规划，它的对偶问题是在满足约束 $\lambda \geq 0$ 的条件下极大化对偶函数g。当且仅当 $c + A^T v - \lambda = 0$ 时对偶函数有界。因此，可得一个等价问题：

$$\begin{aligned} & \text{maximize } -b^T v \\ & \text{subject to } c + A^T v - \lambda = 0 \\ & \qquad \qquad \lambda \geq 0 \end{aligned}$$

这个问题可进一步表述为：

$$\begin{aligned} & \text{maximize } -b^T v \\ & \text{subject to } A^T v + c \geq 0 \end{aligned}$$

KKT最优性条件

原问题最优值用 p^* 表示，Lagrange对偶问题的最优值用 d^* 表示，则有：

$$d^* \leq p^*$$

即使原问题不是凸问题，这个不等式也成立，这个性质称为弱对偶性。当原问题很难求解时，弱对偶不等式可以给原问题最优值一个下界

如果等式 $d^* = p^*$ 成立，即最优对偶间隙是零，那么强对偶性成立。一般情况下，强对偶性是不成立的。但如果原问题是凸问题，强对偶性一般成立

假设强对偶性成立，令 x^* 是原问题的最优解， (λ^*, v^*) 是对偶问题的最优解，因此：

$$\begin{aligned} f_0(x^*) &= g(\lambda^*, v^*) \\ &= \inf_x (f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p v_i^* h_i(x)) \\ &\leq f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p v_i^* h_i(x) \\ &\leq f_0(x) \end{aligned}$$

因此有：

$$\lambda_i^* f_i(x) = 0$$

这个条件称为「**互不松弛性**」

非凸问题的KKT条件

假设强对偶性成立，令 x^* 是原问题的最优解， (λ^*, v^*) 是对偶问题的最优解。因为 $L(x, \lambda^*, v^*)$ 处取得最小值，因此，函数在 x^* 处的导数必须为零，即：

$$\nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) = 0$$

由此可得：

$$\begin{aligned} f_i(x^*) &\leq 0 \\ h_i(x^*) &= 0 \\ \lambda_i^* &\geq 0 \\ \lambda_i^* f_i(x^*) &= 0 \\ \nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) &= 0 \end{aligned}$$

上述式子就是「**KKT条件**」。如果强对偶性成立，那么任意一对原问题和对偶问题的最优解必须满足KKT条件

凸问题的KKT条件

当原问题是凸问题时，满足KKT条件的点也是原、对偶问题的最优解。换言之， $\hat{x}, \hat{\lambda}, \hat{v}$ 是满足KKT条件的点，那么 \hat{x} 和 $(\hat{\lambda}, \hat{v})$ 分别是原问题和对偶问题的最优解，对偶间隙是零

附录

「**凸集的定义**」：如果集合C中任意两点间的线段仍然在C中，即对于任意 $x_1, x_2 \in C$ 和 $0 \leq \theta \leq 1$ 都有：

$$\theta x_1 + (1 - \theta)x_2 \in C$$

那么集合C是凸集

「**凸函数的定义**」：函数 $f: R^n \rightarrow R$ 的定义域是 $dom\ f$ ，如果 $dom\ f$ 是凸集，且对于任意 $x, y \in dom\ f$ 和任意 $0 \leq \theta \leq 1$ ，有：

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y)$$

从几何意义上来看，上述不等式意味着点 $(x, f(x))$ 和 $(y, f(y))$ 之间的线段在函数 f 的上方

如果函数 $-f$ 是凸的，那么函数 f 是凹的

「**凸函数与逐点上确界**」：几乎所有的凸函数都可以表示成一组仿射函数的逐点上确界

「**凸优化问题定义**」：凸优化问题是形如：

$$\begin{aligned} & \text{minimize } f_0(x) \\ & \text{subject to } f_i(x) \leq 0 \\ & \qquad \qquad a_i^T x = b_i \end{aligned}$$

的问题，凸优化问题有三个附加的要求：

- 目标函数必须是凸的
- 不等式约束函数必须是凸的
- 等式约束函数必须是仿射的



