

品 《凸优化读书笔记》第三... 	2021-03-27 21:32:19
品 《凸优化读书笔记》第二... 	2021-03-17 16:57:40
品 《凸优化读书笔记》第一... 	2021-03-17 16:40:09
品 【模型篇】：CTR预估之F... 	2021-08-20 23:34:59
品 【模型篇】：CTR预估之x... 	2021-08-17 22:52:33
品 【模型篇】：CTR预估之... 	2021-08-15 11:13:27
品 [模型篇]: CTR预估之AF... 	2021-08-13 22:33:57
品 【模型篇】：CTR预估之... 	2021-08-11 21:54:42
品 【模型篇】：适用于稀疏... 	2021-08-06 21:54:44
品 【模型篇】：Factorizatio... 	2021-08-06 15:41:31
品 【模型篇】：GBDT+LR在... 	2021-08-05 21:18:34
品 【模型篇】XGBoost: A S... 	2021-08-05 16:31:34
品 深入聊聊深度学习中的前... 	2021-05-28 22:19:41
品 阿里巴巴多分市场下的广... 	2021-05-28 22:18:30
品 雅虎在线广告中的预算平... 	2021-05-23 13:30:00
品 基于多点控制的最优竞价... 	2021-05-16 21:12:16
品 线性规划在广告排序中的... 	2021-05-16 20:49:09
品 《凸优化》读书笔记第四... 	2021-05-09 09:53:56
品 广告拍卖机制及OCPX智... 	2021-03-31 09:18:20
品 广告机制论文&书籍梳理 	2021-03-28 16:38:16
品 《凸优化读书笔记》第三... 	2021-03-27 21:32:19
品 《凸优化读书笔记》第二... 	2021-03-17 16:57:40
品 《凸优化读书笔记》第一... 	2021-03-17 16:40:09
品 PID(Proportion Integratio... 	2021-03-14 12:17:40
品 	2021-03-11 23:45:15
品 【广告预算控制】Linkedln 	2021-03-06 22:18:48
品 深度学习中的序列建模 	2021-02-16 18:04:53
品 博弈论与经济学的关系 	2021-02-16 17:37:10
品 深度学习中的数值优化问题 	2021-02-07 13:03:47
品 深度学习中的概率论知识 	2021-02-01 09:58:49
品 MacOS环境配置python+... 	2021-01-24 20:37:06
品 计算广告简介 	2021-01-17 20:23:42
品 MySQL服务查询优化 	2021-01-14 12:42:57
品 机器学习基础 	2021-01-08 19:17:07

Lagrange函数及其对偶函数

对于标准形式的优化问题：

$$\begin{aligned} & minimize \quad f_0(x) \\ & subject \ to \quad f_i(x) \leq 0, i = 1, 2, \dots, m \\ & \quad \quad \quad h_i(x) = 0, i = 1, 2, \dots, p \end{aligned}$$

拉格朗日函数为：

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)$$

向量 λ 和 v 是对偶变量或者是这个式子的Lagrange乘子

Lagrange对偶函数是Lagrange函数关于 x 取得的最小值：

$$\begin{aligned} g(\lambda, v) &= \inf_{x \in D} L(x, \lambda, v) \\ &= \inf_{x \in D} (f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)) \end{aligned}$$

对偶函数是一族关于 $(\lambda, \ v)$ 的放射函数的逐点下确界，所以即使原问题不是凸的，对偶函数也是凹的

对偶函数构成了原问题最优值 p^* 的下界：即对任意 $\lambda \geq 0$ 和 v ，下式成立：

$$g(\lambda, v) \leq p^*$$

证明：

设 \hat{x} 是原问题的一个可行点，即 $f_i(\hat{x}) \leq 0, h_i(x) = 0$ ，则有：

$$\sum_i^m \lambda_i f_i(\hat{x}) + \sum_{i=1}^p v_i h_i(\hat{x}) \leq 0$$

代入Lagrange函数有：

$$\begin{aligned} L(\hat{x}, \lambda, v) &= f_0(\hat{x}) + \sum_{i=1}^m \lambda_i f_i(\hat{x}) + \sum_{i=1}^p v_i h_i(\hat{x}) \\ &\leq f_0(\hat{x}) \end{aligned}$$

因此：

$$g(\lambda, v) \leq L(\hat{x}, \lambda, v) \leq f_0(\hat{x})$$

考虑标准形式的线性规划问题：

$$\begin{aligned} & minimize \quad c^T x \\ & subject \ to \quad Ax = b \\ & \quad \quad \quad x \geq 0 \end{aligned}$$

其拉格朗日函数为：

$$\begin{aligned} L(x, \lambda, v) &= c^T x - \sum_{i=1}^n \lambda_i x_i + v^T (Ax - b) \\ &= -bv^T + (c + A^T v - \lambda)^T x \end{aligned}$$

对偶函数为：

$$\begin{aligned} g(\lambda, v) &= \inf_x L(x, \lambda, v) \\ &= -b^T v + \inf_x (c + A^T v - \lambda)^T x \end{aligned}$$

线性函数只有恒为0时才有下界，因此：

$$g(\lambda, v) = \begin{cases} -b^T v & c + A^T v - \lambda = 0 \\ -\infty & \text{其它情况} \end{cases}$$

Lagrange对偶问题

Lagrange对偶函数给出了优化问题最优值 p^* 的一个下界，一个自然的问题是：从Lagrange函数能够得到的最好下界是什么？可以将这个问题表述为优化问题：

$$\begin{aligned} & maxmize \quad g(\lambda, v) \\ & subject \ to \quad \lambda \geq 0 \end{aligned}$$

Lagrange对偶问题是一个凸优化问题，这是因为极大化的目标函数是凹函数，且约束集合是凸集

很多情况下，我们可以识别出函数g的定义域的仿射包，并将其表示为一系列线性等式约束，这样处理之后可以得到一个等价的问题

对于标准形式的线性规划，它的对偶问题是在满足约束 $\lambda \geq 0$ 的条件下极大化对偶函数g。当且仅当 $c + A^T v - \lambda = 0$ 时对偶函数有界。因此，可得一个等价问题：

$$\begin{aligned} & maxmize \quad -b^T v \\ & subject \ to \quad c + A^T v - \lambda = 0 \\ & \quad \quad \quad \lambda \geq 0 \end{aligned}$$

这个问题可进一步表述为：

$$\begin{aligned} & maxmize \quad -b^T v \\ & subject \ to \quad A^T v + c \geq 0 \end{aligned}$$

KKT 最优性条件

原问题最优值用 p^* 表示，Lagrange对偶问题的最优值用 d^* 表示，则有：

$$d^* \leq p^*$$

即使原问题不是凸问题，这个不等式也成立，这个性质称为弱对偶性。当原问题很难求解时，弱对偶不等式可以给原问题最优值一个下界

如果等式 $d^* = p^*$ 成立，即最优对偶间隙是零，那么强对偶性成立。一般情况下，强对偶性是不成立的。但如果原问题是凸问题，强对偶性一般成立

假设强对偶性成立，令 x^* 是原问题的最优解， (λ^*, v^*) 是对偶问题的最优解，因此：

$$\begin{aligned} f_0(x^*) &= g(\lambda^*, v^*) \\ &= \inf_x (f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p v_i^* h_i(x)) \\ &\leq f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p v_i^* h_i(x) \\ &\leq f_0(x) \end{aligned}$$

因此有：

$$\lambda_i^* f_i(x) = 0$$

这个条件称为「**互不松弛性**」

非凸问题的KKT条件

假设强对偶性成立，令 x^* 是原问题的最优解， (λ^*, v^*) 是对偶问题的最优解。因为 $L(x, \lambda^*, v^*)$ 处取得最小值，因此，函数在 x^* 处的导数必须为零，即：

$$\nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) = 0$$

由此可得：

$$\begin{aligned} f_i(x^*) &\leq 0 \\ h_i(x^*) &= 0 \\ \lambda_i^* &\geq 0 \\ \lambda_i^* f_i(x^*) &= 0 \\ \nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) &= 0 \end{aligned}$$

上述式子就是「**KKT条件**」。如果强对偶性成立，那么任意一对原问题和对偶问题的最优解必须满足KKT条件

凸问题的KKT条件

当原问题是凸问题时，满足KKT条件的点也是原、对偶问题的最优解。换言之， $\hat{x}, \hat{\lambda}, \hat{v}$ 是满足KKT条件的点，那么 \hat{x} 和 $(\hat{\lambda}, \hat{v})$ 分别是原问题和对偶问题的最优解，对偶间隙是零

附录

「**凸集的定义**」：如果集合C中任意两点间的线段仍然在C中，即对于任意 $x_1, x_2 \in C$ 和 $0 \leq \theta \leq 1$ 都有：

$$\theta x_1 + (1 - \theta)x_2 \in C$$

那么集合C是凸集

「**凸函数的定义**」：函数 $f: R^n \rightarrow R$ 的定义域是 $dom\ f$ ，如果 $dom\ f$ 是凸集，且对于任意 $x, y \in dom\ f$ 和任意 $0 \leq \theta \leq 1$ ，有：

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y)$$

从几何意义上来看，上述不等式意味着点 $(x, f(x))$ 和 $(y, f(y))$ 之间的线段在函数 f 的上方

如果函数 $-f$ 是凸的，那么函数 f 是凹的

「**凸函数与逐点上确界**」：几乎所有的凸函数都可以表示成一组仿射函数的逐点上确界

「**凸优化问题定义**」：凸优化问题是形如：

$$\begin{aligned} & \text{minimize } f_0(x) \\ & \text{subject to } f_i(x) \leq 0 \\ & \qquad \qquad a_i^T x = b_i \end{aligned}$$

的问题，凸优化问题有三个附加的要求：

- 目标函数必须是凸的
- 不等式约束函数必须是凸的
- 等式约束函数必须是仿射的